

Trabalho Prático 2

The Slow & The Calm: Darwin's Edition

Trabalho realizado por:

- Mário Lemos (2019216792)
- Pedro Martins (2019216826)
- Regina Amado (2019210521)

Meta 1 - Modelação e desenvolvimento do Algoritmo Genético:

Nesta primeira meta iremos implementar os diversos pseudocódigos fornecidos, características do Algoritmo Genético. Estes encontram-se separados em 6 categorias:

- Recombinação
- Mutação
- Seleção de Pais
- Seleção de Sobreviventes
- Parameterização
- Aptidão (Fitness)

De todos estes aspetos, destaca-se a importância da aptidão no cumulativo do algoritmo em questão. Aqui iremos dispor de vários parâmetros de comparação, de forma a poder selecionar os melhores carros e, respetivamente, desenvolver uma geração melhor e mais capaz de alcançar os objetivos em questão. Para os efeitos de testes, temos ao nosso dispor 4 cenários, 2 de desenvolvimento dos veículos e 2 de testes individuais do melhor genoma encontrado. Este genoma é caracterizado por uma sequência de 256 dígitos (28 bits), que alternam entre 0 e 1, e constituem os 8 vectores característicos de cada veículo, possuindo informação sobre o seu tamanho, ângulo, colocação da roda e raio da mesma.

Desenvolvimento da Fitness inicial:

Aqui encontra-se uma das partes mais importantes deste projeto, desenvolver várias funções de aptidão que consigam tirar partido das características e desempenho de certos veículos, guardando e aproveitando o seu sucesso. Para isso, teremos ao nosso dispor 6 estatísticas de cada veículo:

- **Distância máxima percorrida (MaxDistance):** Representa a distância alcançada pelo veículo após concluir o seu percurso.
- **Velocidade máxima atingida (MaxVelocity):** A velocidade instantânea máxima alcançada pelo veículo ao longo do percurso.
- **Tempo a percorrer a distância (MaxDistanceTime):** Valor temporal que indica quanto tempo o veículo demorou a alcançar a distância máxima.
- **Número de rodas (NumberOfWheels):** A quantidade de rodas presentes no veículo em questão.
- **Massa do carro (CarMass):** A massa total do carro desenvolvido.

- **Conclusão do percurso (IsCompleted):** Valor 0 ou 1 representativo do facto de que o carro conseguiu terminar o trajeto ou não.

Dispondo destes valores, podemos então começar a desenvolver uma função de aptidão inicial. Como primeira base, iremos definir a fitness como um valor ou 0 ou 1, representativo da **Conclusão do percurso**, assim, o nosso algoritmo evolutivo irá selecionar como pai e sobrevivente, os veículos que conseguem terminar com sucesso o percurso.

c.fitness = isCompleted;

Testes e validação das funcionalidades implementadas:

Com todas as categorias do Algoritmo Genético corretamente implementadas e uma função de aptidão desenvolvida podemos realizar os primeiros testes. Para isso iremos recorrer ao cenário **GapRoad**. É de notar que, de forma a validar e tornar consistentes os resultados obtidos, cada experiência será executada 3 vezes. O número de gerações é sempre 30, o que faz com que o tempo de execução de cada experiência ronde os 30 minutos.

Primeira Execução:

O primeiro carro a conseguir completar o percurso alcançou a meta na 14ª geração (6 rodas, 211 de massa e 73.5s para acabar o caminho). De seguida, este foi reinserido na população e usado como progenitor em futuras gerações. Na geração 18, outro carro conseguiu alcançar a meta, sendo também usado com o primeiro na criação de descendentes. Este veículo denotou ser mais fraco que o inicial em todos os aspetos de comparação.

Completoou o percurso	Menor tempo	Menor massa	Menor nº de rodas
2	73.44s	211	6

Tabela 1 – Dados estatísticos da primeira execução com fitness inicial

Segunda Execução:

Nesta execução, apenas na 27ª geração um carro foi capaz de alcançar a meta. Ora, com a função de adaptação usada, todas as gerações anteriores foram obtidas de forma aleatória, o que prejudicou o sucesso estatístico desta execução. Até ao fim do percurso, mais nenhum carro diferente conseguiu terminar.

Completoou o percurso	Menor tempo	Menor massa	Menor nº de rodas
1	76.47s	215.5	8

Tabela 2 – Dados estatísticos da segunda execução com fitness inicial

Terceira Execução:

Esta execução foi a mais bem sucedida, em parte devido ao facto de que logo na 6ª geração um carro foi capaz de chegar ao fim do percurso e assim ser adicionado como progenitor para futuras gerações (73.32s, 8 rodas e 193 de massa). Nas gerações 17 e 26, terminou um novo carro o percurso; embora nenhum destes tenha conseguido superar o primeiro em número inferior de rodas e massa, o terceiro cronometrou um tempo ligeiramente inferior (72.15s).

Completoou o percurso	Menor tempo	Menor massa	Menor nº de rodas
3	72.15s	193	8

Tabela 3 – Dados estatísticos da terceira execução com fitness inicial

De seguida, decidimos começar a alterar a função de *fitness*. Uma grande desvantagem que notámos foi a dificuldade em conseguir encontrar um carro vencedor, tal como foi verificado especialmente na **Experiência 2**. Assim, decidimos adicionar um componente extra; caso o carro não tenha completado o percurso, deve ser usada como fitness a **distância máxima** atingida. Caso complete com sucesso, o valor da fitness é 700, sendo assim superior a qualquer distância.

```
if (isCompleted == 1){c.fitness = 700; }else{c.fitness = maxDistance; }
```

Primeira Execução:

O primeiro carro a chegar ao fim conseguiu-o na 10ª geração. Um novo carro alcançou a meta na 22ª geração, não sendo superior ao primeiro em qualquer critério de avaliação.

Completoou o percurso	Menor tempo	Menor massa	Menor nº de rodas
2	68.15s	196.5	8

Tabela 4 – Dados estatísticos da primeira execução com fitness alterado

Segunda e Terceira Execuções:

Nestas execuções o primeiro carro completou o percurso na 14ª e 8ª gerações, respetivamente. Obtiveram um tempo médio de término do caminho de 74s e uma massa menor de 176.

Completoou o percurso	Menor tempo	Menor massa	Menor nº de rodas
3	74.12s	176.1	8

Tabela 5 – Dados estatísticos da segunda e terceira execuções com fitness alterada

Conclusões:

Com a nova função de fitness, os carros conseguem chegar ao fim em gerações mais baixas (**Média da fitness 1:** 16ª geração | **Média da fitness 2:** 10ª geração). Com isto os carros têm mais tempo para gerar descendentes superiores e, assim, atingir melhores resultados nas estatísticas apresentadas nas tabelas. Ao usar a distância máxima, garantimos que carros com melhor performance são selecionados para progenitores face ao fator aleatório da 1ª fitness.

Meta 2 - Experimentação e análise

Introdução:

Nesta segunda meta, o principal objetivo é continuar o processo implementado na **Meta 1**, de forma a poder alcançar o melhor desempenho possível nos cenários disponibilizados e tentar/conseguir obter um carro capaz de completar o *HillRoad*. Logo após a finalização da meta anterior começámos a pensar na implementação de uma melhor função de adaptação, visto que a presente apenas distinguia carros que completavam e, no caso destes não chegarem ao fim, selecionar da população os mais promissores, ou seja, aqueles que percorriam a maior distância.

Ora, foi notório que esta solução apresentava uma grande estagnação devido a um fator de extrema importância, não existia qualquer critério de preferência na seleção dos melhores carros (aqueles que terminavam o percurso), o que levava ao fim da competição visto que não existia qualquer fator de importância a ser analisado pela função de adaptação. Assim decidimos implementar uma nova vertente à fitness, agora, caso o carro tenha completado com sucesso o percurso, é selecionado aquele que demorou menor tempo a percorrer o trajeto. Com esta alteração garantimos que a ordem de evolução se mantém mesmo após um veículo completar o cenário, continuando a tentar selecionar melhores carros e reduzindo drasticamente o nível de estagnação.

$$\text{fitnessAnterior} + (200 - \text{MaxDistanceTime})$$

Com esta porção de código (apenas aplicável a carros que terminam), garantimos que aqueles com menor tempo terão maior *fitness* e, assim, serão selecionados como progenitores das futuras gerações. De seguida apresentamos uma representação gráfica dos valores a esperar para a aptidão de cada veículo. Os limites situam-se em **0** e **900** sendo que, quanto maior este valor for, melhor o carro é e vice-versa:



Após esta solução, passámos a uma das fases mais importantes do trabalho, os testes relativos às experiências. Em suma, irão ser realizadas cinco experiências com parâmetros diferentes, cada uma com três execuções, de forma a poder determinar qual combinação de

parâmetros acarreta uma melhor solução para gerar e evoluir os veículos em questão. Na **Tabela 6**, encontram-se descritos os parâmetros usados nas próximas iterações:

	Mutação	Elitismo	Torneio	Crossover	Nº Gerações
Experiência 1	0.05	0	5	0.9	30
Experiência 2	0.2				
Experiência 3	0.05	2			
Experiência 4	0.2				
Experiência 5	0.05		2		

Tabela 6 – Lista de parâmetros agrupados por experiência a executar

Como é possível observar na **Tabela 6**, estes parâmetros divergem de uma experiência para a outra, excetuando o crossover e o número de gerações que, para os propósitos deste estudo, são constantes e imutáveis. O objetivo desta fase é descobrir qual é a melhor combinação de parâmetros, de forma a poder aprofundar o nosso conhecimento e usá-los em testes futuros. Como fatores de sucesso, iremos observar diversas medidas:

- **Número de carros distintos a terminar:** Esta métrica é de grande importância, uma vez que quanto maior for o número de soluções distintas numa execução a terminar o percurso, maior o número de soluções geradas, aumentando assim o potencial de desenvolver um carro com um bom genótipo.
- **Menor tempo a percorrer o circuito:** Este fator é importante na medida em que procuramos uma solução eficaz e, o menor tempo necessário a percorrer o trajeto está associado com um melhor desempenho. Tendo em conta a volatilidade e o facto de apenas serem realizadas 3 execuções por experiência, assumimos o fator ligeiramente aleatório deste critério, pelo que terá uma conotação inferior ao anterior.
- **Menor massa e número de rodas:** O veículo desejado deve possuir uma massa e número de rodas baixo, de forma a poder ser mais ágil, versátil e sem peso desnecessário. Com isto em mente, um valor baixo nestes dois critérios está associado a um veículo mais rápido e com melhor capacidade de desenvolvimento.
- **Média da fitness da execução:** Por fim, interessa-nos saber se a *fitness* desenvolvida se mantém constante e alta ao longo da experiência.

Tendo em conta estas quatro métricas, iremos iniciar as execuções, seguindo a ordem ascendente que consta na **Tabela 6**.

Experimentação com as combinações de parâmetros:

1ª Experiência:

Na **Tabela 7** encontram-se presentes os resultados para as 3 execuções efetuadas, assim como uma média de alguns critérios:

	Completo o percurso	Menor Tempo	Menor Massa	Menor nº de rodas	Aptidão Média	Melhor Aptidão
Execução 1	2	85.24s	139.5	6	104.7	814
Execução 2	1	67.94s	184.5	8	95.6	832
Execução 3	2	78.47s	161.5	7	109.5	821
Média	1.66	77.22s	161.8	7	103.2	822.3
Melhor/Total	5	67.94s	139.5	6	109.5	832

Tabela 7 – Resultados das 3 execuções para a Experiência 1

Como é possível observar na **Tabela 7**, notou-se uma média de 1.66 carros a terminarem o percurso por execução com estes parâmetros. A menor massa e menor número de rodas são aceitáveis contudo, comparando estes resultados com os das primeiras duas funções de adaptação (cujo desempenho é presumidamente inferior a esta função de adaptação), constata-se a semelhança e respetiva mediocridade destes resultados, levando a um lento progresso e desenvolvimento.

Outro fator de grande importância é a aptidão média de cada execução e a média das três execuções. Com um valor inferior a 100, demonstra-se mais uma vez a fraca capacidade de manter um bom genótipo na população, o que desde logo nos indica uma relativa importância de usar como elitismo um valor diferente de 0 (**Experiências 3, 4 e 5**). Isto pode também explicar os valores medianos explicados no parágrafo anterior; com a constante renovação do genótipo, perdem-se vitais características aprendidas em gerações anteriores e cujo papel evolutivo é bastante crucial e elevado. De seguida iremos usar na **Experiência 2** uma mutação de 0.2 (em vez de 0.05) e observar os diferentes resultados face a esta **Experiência 1**.

2ª Experiência:

Na **Tabela 8** encontram-se presentes os resultados para as 3 execuções efetuadas, assim como uma média de alguns critérios:

	Completo o percurso	Menor Tempo	Menor Massa	Menor nº de rodas	Aptidão Média	Melhor Aptidão
Execução 1	6	66.83s	170	5	82.63	833
Execução 2	3	67.03s	177	7	80.94	832
Execução 3	6	70.34s	150	7	84.36	829
Média	5	68.07s	165.6	6.3	82.64	831.3
Melhor/Total	15	66.83s	150	5	84.36	833

Tabela 8 – Resultados das 3 execuções para a Experiência 2

Analisando os resultados que constam na **Tabela 8**, nota-se uma clara diferença comparativamente à Experiência 1. Ao longo das três execuções, 15 carros diferentes terminaram o percurso, o que culmina numa média de 5 carros por execução. Com especial destaque para o menor número de rodas, os outros padrões em análise encontram-se dentro do esperado, com uma *fitness* melhor de 833, apenas 1 superior à **Experiência 1**. Numa análise superficial, conseguimos destacar um aspeto crucial, a grande capacidade de gerar diferentes soluções e carros, o que se pode explicar devido ao seu valor elevado de mutação, cerca de 4 vezes superior àquele utilizado na experiência anterior, tornando-o assim um parâmetro vital, se queremos gerar num número limitado de gerações o maior número de soluções aceitáveis.

Contudo, continua-se a notar dificuldades em manter a aptidão num valor relativamente elevado (com a aptidão média a baixar ainda mais, o que pode ser explicado devido ao facto de que, com a maior mutação, o genótipo fica mais danificado/mutado e alterado para as futuras gerações), visto que o elitismo continua a 0, o melhor genótipo perde-se nos progenitores das gerações futuras, o que, por um lado, é propício a constantemente renovar e, possivelmente, gerar um bom genótipo, contudo por outro pode costar gerações perdidas onde nenhum carro decente consegue terminar, o que se prova bastante prejudicial num número tão pequeno de gerações. Para as futuras experiências, o elitismo passará para 2, de forma a guardar para a próxima geração os dois melhores carros.

3ª Experiência:

Na **Tabela 9** encontram-se presentes os resultados para as 3 execuções efetuadas, assim como uma média de alguns critérios:

	Completo o percurso	Menor Tempo	Menor Massa	Menor nº de rodas	Aptidão Média	Melhor Aptidão
Execução 1	2	70.73s	135	7	183.48	829.26
Execução 2	2	68.46s	184	8	187.58	831.53
Execução 3	3	68.42s	176	4	201.09	831.58
Média	2.3	69.2s	165	6.3	190.71	830.79
Melhor/Total	7	68.42s	135	4	201.09	831.58

Tabela 9 – Resultados das 3 execuções para a Experiência 3

Observando a **Tabela 9** o primeiro aspeto que constatamos é um ganho substancial do nível de aptidão médias das três execuções, comparativamente às experiências anteriores. Aqui podemos diretamente observar o impacto de ter o elitismo a 2, obtemos uma combinação que premeia e mantém vivo para as próximas gerações os melhores veículos a percorrer o trajeto, garantindo assim que o seu genótipo não é perdido. Comparativamente à **Experiência 1**, observa-se um ganho de 87.5 na aptidão média e 108 quando comparado com a **Experiência 2**.

É também de notar que, apesar de a mutação voltar para 0.05 (à semelhança da **Experiência 1**), o número de carros diferentes que conseguiram completar o percurso (oito) é bastante superior àquele da **Experiência 1**, comprovando mais uma vez a eficácia e importância do elitismo existir no algoritmo genético.

Relativamente ao resto dos dados, o menor tempo registado foi de 68.42s, 135 de massa e 4 rodas, culminando numa melhor *fitness* de 831.58. Estes valores encontram-se dentro do esperado para as execuções. Na experiência seguinte iremos testar devolver a mutação de 0.2 ao algoritmo genético, mantendo o elitismo desta experiência (dois). Até agora, estes dois parâmetros demonstraram-se vitais para a geração diversa de novas soluções e a consistência do desenvolvimento genético das futuras gerações, pelo que espera-se que a próxima experiência possa confirmar a veracidade desta premissa.

4ª Experiência:

Na **Tabela 10** encontram-se presentes os resultados para as 3 execuções efetuadas, assim como uma média de alguns critérios:

	Completo o percurso	Menor Tempo	Menor Massa	Menor nº de rodas	Aptidão Média	Melhor Aptidão
Execução 1	0	65.6s	149.5	6	109.46	590
Execução 2	3	68.4s	159.5	7	146.72	831
Execução 3	6	67.2s	194.3	8	139.12	832
Média	3	67.1s	167.8	7	131.76	751
Melhor/Total	9	67.2s	149.5	6	146.72	832

Tabela 10 – Resultados das 3 execuções para a Experiência 4

Ao analisar os dados obtidos das três execuções com a **Experiência 4**, constata-se que foram nove o número de carros diferentes que conseguiram alcançar o fim do percurso. É de realçar que, devido ao número limitado de gerações, e ao fator aleatório inerente a cada iteração, na primeira execução de todas 0 carros terminaram o trajeto. Este facto prejudicou o resultado final (nove carros diferentes) pelo que teremos isto em consideração na nossa análise. Em suma, estes dados confirmam a nossa percepção anterior, **elitismo** e **mutação** são duas vertentes cruciais na evolução genética; a aptidão média continua bastante elevada (muito devido ao elitismo ser 2) e o número de soluções diferentes que atingiram sucesso também se encontra acima da Experiência anterior, mesmo depois da primeira execução falhada. Em vez de gerarmos uma **4ª Execução**, decidimos manter estes valores uma vez que nos servem de indicador para uma outra característica, a volatilidade deste nível de mutação. Ora com um valor de 0.2 neste parâmetro a recombinação genética dos descendentes é relativamente elevada, o que tanto pode permitir a existência de iterações muito boas (como a **Execução 3**) mas também outras menos boas (**Execução 1**).

Apenas tendo em consideração carros que terminaram, a menor massa foi de 159.5, menos tempo de 68.4s e menor número de rodas de 7. A aptidão média fixou-se nos 131.76, a cerca de 60 da Experiência anterior e bastante à frente das duas primeiras. Por fim, iremos passar à última experiência, onde iremos reverter a mutação para 0.05 e, pela primeira vez, alterar o valor do torneio para 2, o que quer dizer que a seleção do número de potenciais progenitores vai diminuir.

5ª Experiência:

Na **Tabela 11** encontram-se presentes os resultados para as 3 execuções efetuadas, assim como uma média de alguns critérios:

	Completo o percurso	Menor Tempo	Menor Massa	Menor nº de rodas	Aptidão Média	Melhor Aptidão
Execução 1	1	78.7s	184.5	7	154.53	821
Execução 2	3	74.5s	164.5	7	175.83	826
Execução 3	2	67.3s	163.1	8	161.74	832
Média	2	73.5s	170.7	7.3	164.03	826.3
Melhor/Total	6	67.3s	163.1	7	175.83	832

Tabela 11 – Resultados das 3 execuções para a Experiência 5

Por fim, denota-se que 6 carros diferentes terminaram o percurso ao longo das três execuções. O menor tempo é de 67.3s, a menor massa de 163.1 e o menor número de rodas é 7. A melhor *fitness* é de 832 e como aptidão média, o valor de 164.03 está cerca de 32 à frente da **Experiência 4**. Estes valores similares demonstram, mais uma vez, a eficácia do elitismo no código genético. Os diferentes carros gerados que tiveram sucesso (seis), é inferior ao da experiência passada, denotando-se assim a falta de um valor de mutação mais elevado na busca por obter um veículo melhor.

Ao longo destas experiências, chegámos à conclusão que o valor de mutação mais baixo (0.05) poderia ser benéfico, no caso de o número de gerações ser bastante superior ao atual (provavelmente na ordem das centenas), assim garantiríamos uma curva mais estável de evolução sem danificar muito o genótipo dos descendentes; com este número de gerações tão baixo, é precisa uma mutação maior, se queremos alcançar um carro melhor, sendo claro que se trata de uma situação de risco/benefício, onde o risco de danificar o genótipo e prejudicar a evolução é maior (tal como se verificou na primeira execução da **Experiência 4**), mas os benefícios são também eles maiores (maior número de soluções diferentes boas geradas).

Conclusões tiradas das cinco Experiências:

Dando por terminadas as cinco experiências, iremos agora refletir e ponderar os dados gerados, de forma a poder tirar as devidas elações e usar os melhores parâmetros nos futuros

testes de aptidão. Nos gráficos seguintes, temos uma exposição de alguns fatores importantes e cuja comparação é vital:




Gráfico 1 – Evolução da aptidão média das 5 experiências ao longo de 3 execuções

No **Gráfico 1** é possível obter uma melhor representação da aptidão média. As experiências com elitismo 0 (1 e 2) são consistentemente inferiores às restantes relativamente à aptidão média, corroborando as elações tiradas anteriormente, elitismo é crucial se queremos preservar a evolução do melhor genótipo, em vez de revolucioná-lo a cada iteração.




Gráfico 2 – Evolução do número de carros diferentes a terminar o percurso das 5 experiências

No **Gráfico 2**, pretendemos ter uma perspetiva visual dos carros diferentes que terminaram o trajeto em cada execução. As Experiências com mutação 0.05 (1, 3 e 5) são aquelas que geram o menor número de soluções, enquanto que as outras duas (0.2 de mutação), geram o maior número de carros, apesar de serem menos consistentes e com alguns outliers (como é o caso da primeira execução da experiência 4, onde 0 carros terminaram). Apesar de uma maior mutação ser propícia a alguma aleatoriedade e possível fracasso, os benefícios são superiores, uma vez que geramos uma larga junção de concorrentes capazes, ao invés de ter um número consistentemente inferior, precisamente o que é necessário numa experiência com poucas gerações. Correlacionando com o **Gráfico 1**, também é interessante constatar que as Experiências 2 e 4 (com mutação superior), possuem a menor adaptação média do seu respetivo grupo de elitismo, ficando comprovado o risco e sacrifício efetuado para gerar este número elevado de veículos promissores.

Em suma, e tendo em conta toda esta informação, podemos chegar à conclusão que **elitismo** e **mutação** são dois aspetos fundamentais do algoritmo genético; como tal, mantê-los na sua configuração mais elevada é benéfico para os moldes nos quais se inserem as Experiências. Tendo isto em consideração, iremos usar os parâmetros da **Experiência 4** como referência para futuros testes, uma vez que esta reúne estas duas condições. A **Experiência 5** poderia ser considerada devido aos bons resultados derivados do uso de torneio de 5, contudo a sua mutação inferior prejudica bastante o seu desempenho. A **Experiência 2**, apesar de gerar um grande número de carros promissores, tem uma aptidão média bastante baixa, derivado do elitismo a 0, prejudicando a evolução das gerações. A **Experiência 3** tem uma aptidão média muito forte, contudo o desenvolvimento é baixo, graças ao valor de mutação inferior.

Novas funções de adaptação:

Após terminarmos os testes e determinarmos os melhores parâmetros, resta-nos ajustar a função de adaptação de forma a encontrar uma combinação boa com as várias estatísticas dos veículos. Até agora usamos eficazmente três deles (isCompleted, maxDistance, maxDistanceTime) contudo achamos que ainda é possível otimizar a nossa solução. Como já foi estabelecido, a massa dos carros, número de rodas são dois aspetos importantes se queremos obter um carro otimizado e capaz de atingir o fim do percurso mais exigente *HillRoad*. Assim, esperamos incorporar estes dois fatores, mais a velocidade máxima atingida, de forma a poder beneficiar e prejudicar diversos componentes de cada carro, obtendo assim um candidato ideal para gerar os descendentes.

$$\text{Fitness} = 0.8 * \text{MaxDistance} + 0.2 * \text{MaxVelocity} - 0.2 * \text{CarMass} - 20 * \text{NumberOfWheels} + 200 * \text{IsCompleted}$$



Como está representado na escala acima, agora a nossa função de adaptação enquadra-se nos limites estimados **-360** a **675**. O limite inferior foi obtido assumindo 0 de bonificação (MaxDistance, MaxVelocity e IsRoadComplete são 0) e uma penalização máxima (CarMass é 300,

valor este obtido através de experimentação e *NumberOfWheels* 15, valor máximo permitido pelo algoritmo genético). Na fórmula usada beneficiamos a distância atingida, velocidade máxima e se o percurso foi concluindo, em troca penalizamos a massa e número de rodas excessivas, tendo como objetivo tornar a nossa melhor solução o mais leve e ágil possível. Na tabela seguinte encontram-se os resultados obtidos após as três execuções no *GapRoad* com a nova função de adaptação e os parâmetros da **Experiência 4**:

	Completo o percurso	Menor Tempo	Menor Massa	Menor nº de rodas	Aptidão Média	Melhor Aptidão
Execução 1	4	87.59s	131.5	6	-54.09	580
Execução 2	4	69.81s	129	7	-60.41	560
Execução 3	2	71.98s	171	5	-56.39	588
Média	3.3	76.46s	143.8	6	-56.96	576
Melhor/Total	10	69.81s	129	5	-54.09	588

Tabela 12 – Resultados das 3 execuções para a nova função de adaptação

Como é possível observar na **Tabela 12**, é notória a diminuição da massa comparativamente a qualquer outra experiência realizada com as funções de aptidão antigas; com uma média de menor massa de 143.8, este valor é, comparativamente com a mesma estatística para a **Experiência 4 (Tabela 10)**, 24 unidades de massa inferior. A média de rodas também é menor, por uma de diferença. O facto do tempo ter aumentado corrobora a mudança do objetivo principal das experimentações para o desenvolvimento de gerações mais ágeis e leves, de forma a conseguir alcançar um melhor desenvolvimento no cenário *HillRoad*. Os valores da fitness não podem ser comparados a outros obtidos previamente, uma vez que a nossa função de aptidão mudou completamente, assim como os valores considerados positivos ou negativos. O melhor carro obteve 129 de massa e 5 rodas; sendo de realçar os parâmetros escolhidos que, mais uma vez, nos permitiram gerar um grande número de candidatos num número limitado de gerações.

De seguida, iremos proceder a algumas alterações à função prévia de fitness, tendo em conta a maior otimização da massa dos veículos desenvolvidos. O cenário *HillRoad*, objetivo final da sequência de testes, é um percurso de resistência, composto por diversas subidas com alguma complexidade, sendo por isso vital ter uma função de adaptação que evolua no sentido de encontrar uma solução ótima e o mais leve possível, permitindo assim a conclusão do percurso. De seguida, temos a fórmula alterada, com especial destaque para o aumento da penalização da massa dos veículos, ligeira diminuição da penalização do número de rodas e uma diminuição da bonificação para a distância máxima alcançada. Todos os outros parâmetros mantêm-se idênticos:

$$Fitness = 0.4 * MaxDistance + 0.2 * MaxVelocity - 0.4 * CarMass - 10 * NumberOfWheels + 200 * IsCompleted$$



Analisando a escala acima, as estimativas para os limites da nova função de adaptação foram alterados para **-270 a 425**. Assumimos os mesmos critérios que foram usados para explicar a escala anterior, apenas alterando a constante a multiplicar por cada estatística do veículo em questão. De seguida iremos efetuar três testes no cenário GapRoad, com o intuito de perceber se as alterações efetuadas irão levar à conclusão desejada, uma solução mais ágil e leve:

	Completo o percurso	Menor Tempo	Menor Massa	Menor nº de rodas	Aptidão Média	Melhor Aptidão
Execução 1	2	79.3s	154.5	7	-23.65	324
Execução 2	3	81.4s	119.3	6	-18.43	328
Execução 3	4	69.6s	127.1	5	-27.42	327
Média	3	76.8s	133.6	6	-23.17	326.3
Melhor/Total	9	69.6s	119.3	5	-18.43	328

Tabela 13 – Resultados das 3 execuções para a função de adaptação com maior penalização de peso

Analisando os resultados da **Tabela 13**, conseguimos desde já perceber que as alterações funcionaram no sentido de diminuir ainda mais a massa das soluções geradas. Em média, a menor massa é de 119.3, 24.5 unidades de massa inferior à da função de adaptação anterior. O número de rodas é o mesmo, pelo que se continua num bom caminho tendo em conta a evolução da *fitness*. Outras estatísticas, tais como o menor tempo e o número de carros diferentes a completar o trajeto encontram-se dentro do esperado, com resultados muito semelhantes aos registados na experiência anterior (**Tabela 12**). Também é de constatar que, uma vez que alterámos os valores de prémio para a *MaxDistance*, os valores entre os quais a *fitness* se encaixa sofreram de novo alterações, pelo que comparações diretas destes valores com experiências anteriores não surtem nenhum resultado significativo.

No Gráfico seguinte é apresentada uma comparação das menor massas para estas duas últimas funções de adaptação, mais a função usada na determinação das experiências ao longo das 3 execuções de cada experiência, com o objetivo de demonstrar a eficiência e aprendizagem dos conceitos interpretados:




Gráfico 3 – Evolução da menor massa ao longo das 3 execuções

Analisando o **Gráfico 3**, conseguimos visualizar melhor as conclusões obtidas, com cada alteração efetuada à função de adaptação, a massa das soluções tem tendência a diminuir cada vez mais, corroborando as nossas intenções para esta fase do projeto.

Cenário HillRoad:

De seguida, iremos começar a realizar testes no cenário *HillRoad*, cuja dificuldade é bastante superior. Iremos fazer uso da última função de adaptação, uma vez que consideramos, através dos resultados obtidos, que é a mais promissora. Como parâmetros iremos continuar a usar os escolhidos previamente, isto é, aqueles que constam da **Experiência 4 (Tabela 6)**. Uma vez que o cenário mudou, a distância máxima também é diferente, o que significa uma alteração aos limites nos quais a fitness se pode inserir:



Apenas o limite máximo foi alterado, para refletir a nova distância máxima de 360m face aos 656m prévios, encontrando-se agora entre **-270** e **300**. Como o limite inferior não envolve este parâmetro (está a 0), este limite não sofre qualquer alteração. Na tabela seguinte, seguemos os resultados das três primeiras execuções neste novo cenário. Em vez de analisar o menor tempo, passaremos a comparar a distância máxima que cada carro atingiu ao longo do percurso.

	Completo o percurso	Distância Máxima	Menor Massa	Menor nº de rodas	Aptidão Média	Melhor Aptidão
Execução 1	0	228.6	140.5	4	-131.67	-49
Execução 2	0	245.8	129.5	6	-111.77	-45
Execução 3	0	255.9	140.5	6	-113.85	-37
Média	0	243.4	136.8	5.3	-119.09	-43.7
Melhor/Total	0	255.9	129.5	4	-111.77	-37

Tabela 14 – Resultados das 3 execuções iniciais para o cenário HillRoad

Analisando os resultados presentes na **Tabela 14**, podemos logo tirar a conclusão de que 0 carros conseguiram terminar o percurso. Isto expõe a dificuldade que o mesmo representa para o algoritmo genético contudo, existem algumas conclusões iniciais que podemos tirar. Primeiramente, algo que notámos após executar as iterações foi a má alocação da bonificação que alguns carros obtinham, não permitindo o desenvolvimento ótimo da evolução genética para um carro mais leve e capaz, o que terá custado algumas gerações de desenvolvimento. Para combater este problema, decidimos alterar ligeiramente a função de adaptação, de forma a aumentar o prémio da distância percorrida, tendo em conta que o carro que chegou mais longe alcançou os 250m, sendo o trajeto inferior àquele do *GapRoad*:

$$Fitness = MaxDistance + 0.2 * MaxVelocity - 0.4 * CarMass - 10 * NumberOfWheels + 200 * IsCompleted$$



Assim sendo, os nossos novos limites são de **-270** a **525**, tendo sido apenas afetado o limite superior, visto que a distância percorrida representa um prémio, encontrando-se a 0 nas nossas estimativas para o limite inferior da *fitness*.

De seguida, percebemos a dificuldade que representa o trajeto, sobretudo a colina que se encontra no marcador dos 230-260m. Contudo, mesmo com 30 gerações por iteração, um padrão tornou-se aparente, os melhores veículos eram, na sua maioria, relativamente compridos, com rodas à frente e atrás e pouca massa. Estes candidatos conseguiam chegar perto do topo contudo, notávam-se dificuldades em sobrepor a colina. Na **Figura 1**, temos o melhor carro (**Execução 3**), que alcançou 255.9m, a ser avaliado no cenário *HillRoad Evaluation*. Este possui exatamente as mesmas características descritas, contudo fica preso no topo da colina nos 256m.



Figura 1 – Melhor caso nas experiências efetuadas no HillRoad. Cenário HillRoad Evaluation

Através destes resultados, nota-se que a parte intermédia do veículo colide com o topo da elevação, o que o impede de se continuar a movimentar e completar o traçado com sucesso. Pelo que podemos desde já tirar a conclusão de que, provavelmente, uma roda no meio do carro poderá ser suficiente para o mesmo ter a tração necessária no topo da colina para a ultrapassar e, assim, poder terminar o percurso. As duas rodas superiores que constam na Figura 1 são desnecessárias e não interferem com a execução do teste. Na figura seguinte, é apresentado um esboço aproximado de um candidato ideal na estrutura previamente descrita:



Figura 2 – Estrutura aproximada do veículo ideal para o cenário HillRoad

Tendo em conta estas considerações, é do nosso entendimento que esta função de adaptação vai de encontro aos nossos objetivos para este projeto, pelo que iremos realizar múltiplas execuções até alcançar um carro capaz de completar o cenário HillRoad. Pelo que foi visto nas experiências da **Tabela 14**, conseguir alcançar este objetivo em 30 gerações pode ser relativamente complicado.

	Completo o percurso	Distância Máxima	Menor Massa	Menor nº de rodas	Aptidão Média	Melhor Aptidão
Execução 1	0	234.4	118	4	-67.66	149
Execução 2	0	249.9	80.5	6	-68.83	137
Execução 3	0	238.1	112.5	5	-67.96	135
Execução 4	0	235.2	106	5	-68.21	139
Execução 5	1	360	128.5	8	-26.67	456
Média	0	263.5	109.1	5.6	-59.86	203.2
Melhor/Total	1	360	80.5	4	-26.67	456

Tabela 15 – Resultados das execuções até alcançar um carro que completou o cenário HillRoad

Como consta da **Tabela 15**, conseguimos na **5ª Execução** um carro que completou o cenário. Este feito foi alcançado na 18ª geração, com o carro a completar o percurso em 360m, com 8 rodas e 128.5 de massa. Como era de esperar, o veículo possuía uma consituição bastante semelhante ao esboço da **Figura 2**. Apesar do elevado número de rodas, estas encontram-se sobrepostas na frente, atrás e meio do carro. Esta última posição permitiu assim que este conseguisse ultrapassar o pico descrito previamente perto dos 260m. O veículo encontra-se presente na **Figura 3**:




Figura 3 – Veículo que conseguiu completar o cenário HillRoad

Tal como foi descrito anteriormente, é a roda do meio que permite ultrapassar o topo da subida; em execuções anteriores os carros possuíam uma estrutura semelhante contudo, sem o apoio da roda do meio, e apenas uma roda traseira, o carro não possuía tração para terminar o trajeto.

Agora temos de verificar a nossa solução. Para tal, selecionamos o genótipo do melhor carro da execução, que é o mesmo do que conseguiu completar o trajeto, graças à bonificação de 200 se o carro terminou o percurso. Vamos então correr a solução no cenário *HillRoad Evaluation*, que serve para executar apenas um veículo selecionado previamente. Como era de esperar, este mantém-se consistente, completando mais uma vez o percurso, tal como demonstra a **Figura 4**:




Figura 4 – Fim do percurso de avaliação do cenário HillRoad Evaluation

Conclusões:

Depois de conseguirmos terminar o cenário *HillRoad* em menos de 30 gerações, podemos tirar várias conclusões.

O bom funcionamento do algoritmo genético é fortemente influenciado por dois fatores, parameterização e função de adaptação. Relativamente ao primeiro ponto, após múltiplos testes concluímos que de facto a melhor combinação de parâmetros se encontra entre as Experiências 3, 4 e 5 (**Tabela 6**), devido ao elitismo de 2, que permite manter os pais na população e assim evitar a perda do progresso genético; para realizar uma escolha entre estas baseámo-nos no elevado nível de mutação da **Experiência 4** para a selecionar como melhor combinação a usar em testes futuros. Através da experimentação, concluímos que um valor de mutação maior é determinante para encontrar em tão poucas gerações um bom número de candidatos viáveis. No nosso entender, o crescimento que esta mutação demonstra pode-se associar a uma função logarítmica, ou seja, progresso inicial rápido e sucessiva estagnação do progresso à medida que se aumenta o número da geração. Por outro lado, uma menor mutação possui um desenvolvimento mais linear e estável contudo, dado o número de gerações limitado optámos por escolher a mutação maior.

Em termos de função de adaptação, a evolução foi constante ao longo do projeto, com os primeiros objetivos mais direcionados a trabalhar com o cenário *GapRoad*. Para isso trabalhámos sobretudo com a distância máxima e tempo para completar o percurso como forma

de premiar e manter o genótipo dos melhores carros na população, sendo que era notório que, na sua maioria, os carros que terminavam mais rápido eram leves e com um grande comprimento, características essenciais para passar pelos buracos do cenário de forma rápida e eficiente. De seguida o objetivo convergiu em obter uma função de adaptação mais complexa e direcionada a otimizar a massa, número de rodas e velocidade dos veículos, de forma a poder ultrapassar o mais complexo cenário *HillRoad*. Com esse propósito adicionámos penalizações aos carros mais pesados e com maior número de rodas, de forma a baixar estas estatísticas em gerações futuras. Depois de vários testes com diferentes valores, chegámos a uma função que consideramos ideal, e com a qual conseguimos desenvolver, na **5ª Execução**, um carro capaz de percorrer o percurso. Regra geral, todos os carros capaz de tal feito possuem pouca massa, sendo assim mais ágeis, têm um grande comprimento e possuem rodas à frente, meio e atrás no veículo, características que lhe permitem passar todas as colinas e obstáculos deste cenário.

Por fim, consideramos que a estrutura de aprendizagem e testagem que adotámos para este trabalho nos permitiu adquirir um bom nível de conhecimento relativamente aos conceitos de *fitness* e parameterização do algoritmo genético, assim como estes dois interferem diretamente com a evolução de descendentes e geração de inteligência artificial. Ao todo foram realizadas cerca de 50 execuções com o intuito de experimentar, perceber e interpretar as conclusões previamente descritas.